



**Data Science
Academy**

www.datascienceacademy.com.br

Introdução à Inteligência Artificial

Aplicação da Regra de Bayes


À primeira vista, a regra de Bayes não parece muito útil. Ela nos permite calcular o único termo $P(a | b)$ em relação a termos: $P(b | a)$, $P(b)$ e $P(a)$. Mas a regra de Bayes é útil na prática porque existem muitos casos em que fazemos boas estimativas de probabilidade para esses três números e precisamos calcular o quarto número.

$$\Pr(A|B) = \frac{\Pr(B|A) \Pr(A)}{\Pr(B)}$$

Muitas vezes, percebemos o *efeito* como evidência de alguma *causa* desconhecida e gostaríamos de determinar essa causa. Nesse caso, a regra de Bayes torna-se esta fórmula de causa e efeito.

$$P(causa | efeito) = \frac{P(efeito | causa) P(causa)}{P(efeito)}$$

A probabilidade condicional $P(efeito | causa)$ quantifica a relação na direção **causal**, enquanto $P(causa | efeito)$ descreve a direção do **diagnóstico**.



Por exemplo, em uma tarefa como o diagnóstico médico, com frequência temos probabilidades condicionais sobre relacionamentos causais (isto é, o médico conhece $P(sintomas | doenças)$) e quer derivar um diagnóstico $P(doenças | sintomas)$.

Um médico sabe que a meningite faz o paciente ter uma rigidez no pescoço, digamos, durante 70% do tempo. O médico também conhece alguns fatos incondicionais: a probabilidade *a priori* de um paciente ter meningite é 1/50.000, e a probabilidade *a priori* de qualquer paciente ter rigidez no pescoço é 1%. Sendo s a proposição de que o paciente tem rigidez no pescoço e m a proposição de que o paciente tem meningite, temos o resultado de 0,0014 aplicando a regra de Bayes.

$$\begin{aligned}P(s|m) &= 0,7 \\P(m) &= 1/50000 \\P(s) &= 0,01 \\P(m|s) &= \frac{P(s|m)P(m)}{P(s)} = \frac{0,7 \times 1/50000}{0,01} = 0,0014\end{aligned}$$

Ou seja, esperamos que apenas um em 5.000 pacientes com rigidez no pescoço tenha meningite. Note que, embora a rigidez no pescoço seja uma indicação bastante forte de meningite (com probabilidade 0,7), a probabilidade de o paciente estar acometido de meningite permanece pequena. Isso ocorre porque a probabilidade *a priori* sobre rigidez no pescoço é muito mais alta que a probabilidade *a priori* sobre meningite.

Uma pergunta óbvia sobre a regra de Bayes é por que a probabilidade condicional pode estar disponível em um sentido, mas não no outro. No domínio de meningite, talvez o médico saiba que a rigidez no pescoço implica meningite em um entre 5.000 casos; isto é, o médico tem informações quantitativas no sentido do **diagnóstico** de sintomas para causas. Tal médico não tem necessidade de usar a regra de Bayes. Infelizmente, *o conhecimento do diagnóstico frequentemente é mais frágil que o conhecimento causal*. Se houver uma súbita epidemia de meningite, a probabilidade incondicional de meningite, $P(m)$, crescerá. O médico que derivou a probabilidade de diagnóstico $P(m|s)$ diretamente da observação estatística de pacientes antes da epidemia não terá ideia de como atualizar o valor, mas o médico que calcular $P(m|s)$ a partir dos outros três valores verá que $P(m|s)$ deve subir proporcionalmente com $P(m)$. Mais importante ainda, as informações causais $P(s|m)$ *não são afetadas* pela epidemia porque simplesmente refletem o modo como a meningite atua. O uso dessa espécie de conhecimento causal ou baseado em modelos fornece a robustez crucial necessária para tornar os sistemas probabilísticos viáveis no mundo real.

Referências:

Livro: Inteligência Artificial

Autor: Peter Norvig