



# Formação Inteligência Artificial



# Introdução à Inteligência Artificial





# Representação do Conhecimento




# Introdução

# Como representar fatos sobre o mundo?





# Introdução



## A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence

August 31, 1955

*John McCarthy, Marvin L. Minsky,  
Nathaniel Rochester,  
and Claude E. Shannon*





# Introdução

Como fazer as máquinas  
compreenderem as coisas?







Data Science  
Academy

Data Science Academy angelicogfa@gmail.com 5b81f7e45e4cdea2118b4569

# Introdução



Data Science Academy



Data Science Academy





# Introdução







# Introdução

Questões Principais de um Sistema de IA:

Aquisição, Representação e Manipulação de Conhecimento





# Introdução

O que estudaremos neste capítulo?

- Definição de representação do conhecimento
- Engenharia Ontológica
- Categorias, objetos e eventos
- Sistemas de Raciocínio
- Quantificação da Incerteza
- A Regra de Bayes
- Semântica e Inferência Bayesianas
- Raciocínio Probabilístico
- Atividades Práticas em Python para Construção de Agentes Lógicos





# O que é Representação do Conhecimento?

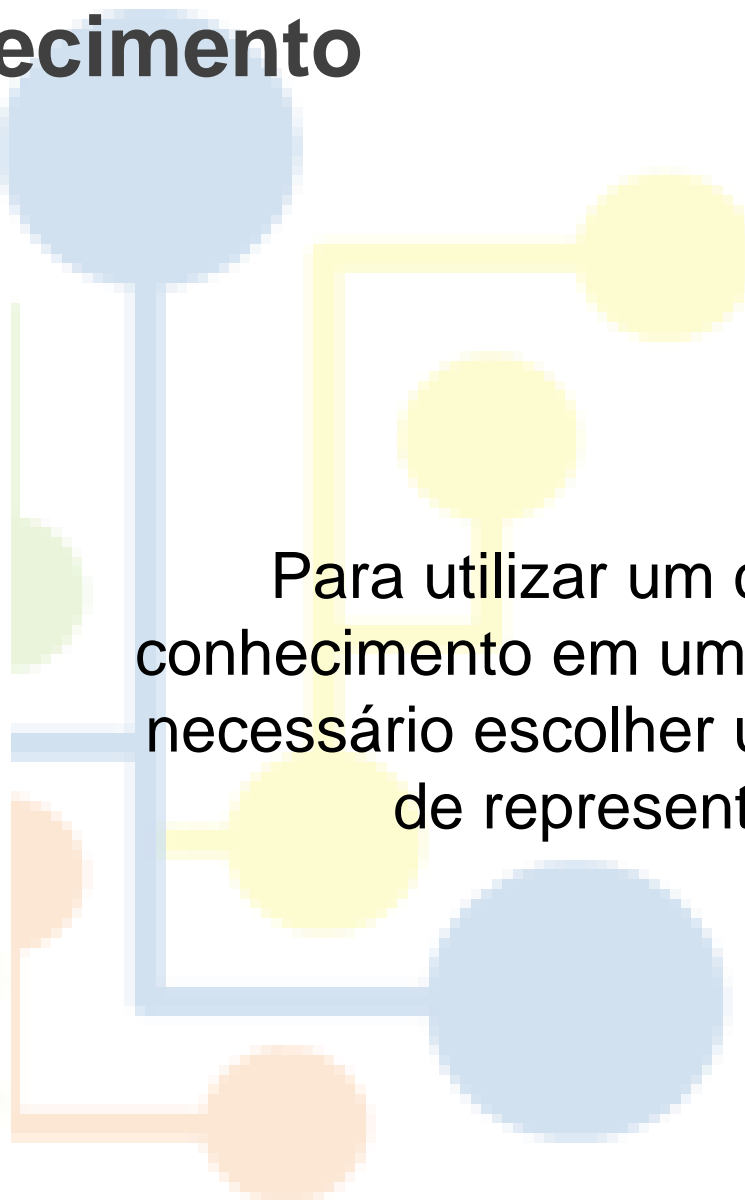




# Representação do Conhecimento



Para utilizar um corpo de conhecimento em uma máquina, é necessário escolher uma maneira de representá-lo







# Representação do Conhecimento






# Representação do Conhecimento





# Representação do Conhecimento

Como transmitir o conhecimento do mundo para um robô ou outro sistema computacional, dando-lhe uma capacidade adequada de raciocínio, de modo que este conhecimento possa ser utilizado para permitir ao sistema uma adaptação e exploração do seu ambiente?





# Representação do Conhecimento

- De que forma o conhecimento pode ser expresso ?
- Como encontrar a linguagem adequada para a representação deste conhecimento ?
- Como formar uma base de conhecimento suficientemente detalhada e que represente a compreensão do domínio ?
- Como realizar inferências automáticas, dando acesso tanto ao conhecimento implícito na base de conhecimento quanto aquele armazenado explicitamente (declarativo)?
- Como o sistema deve proceder na presença de informações incompletas, incorretas ou de senso comum ?







# Representação do Conhecimento

Representação do Conhecimento

A diagram illustrating the relationship between knowledge representation and reasoning. It features a central blue arrow pointing downwards from a green box to a green box. The background is a light gray grid with several colored circles (blue, green, yellow, orange) connected by lines, suggesting a network or graph structure.

Representação do Conhecimento e Raciocínio



# Engenharia Ontológica





# Engenharia Ontológica

A representação de conceitos abstratos é chamada de  
**Engenharia Ontológica.**





# Engenharia Ontológica

Ontologia:

Descrição de conceitos e relacionamentos que devem ser considerados por um agente ou por uma comunidade de agentes.







# Engenharia Ontológica

## Ontologia:

- **Indivíduos:** os objetos básicos
- **Classes:** conjuntos, coleções ou tipos de objetos
- **Atributos:** propriedades, características ou parâmetros que os objetos podem ter e compartilhar
- **Relacionamentos:** as formas como os objetos podem se relacionar com outros objetos



# Engenharia Ontológica

Ontologia:

- **Indivíduos (exemplares)**
- **Classes (conceitos)**
- **Atributos**
- **Relacionamentos**





# Ontologia e Ciência da Computação

Existem na literatura várias definições para o termo ontologia em Ciência da Computação.







# Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

especificação formal quer dizer algo que é legível para os computadores







# Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

explícita são os conceitos, propriedades, relações, funções, restrições e axiomas explicitamente definidos





# Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

conceitualização representa um modelo abstrato de algum fenômeno do mundo real e compartilhada significa conhecimento consensual.







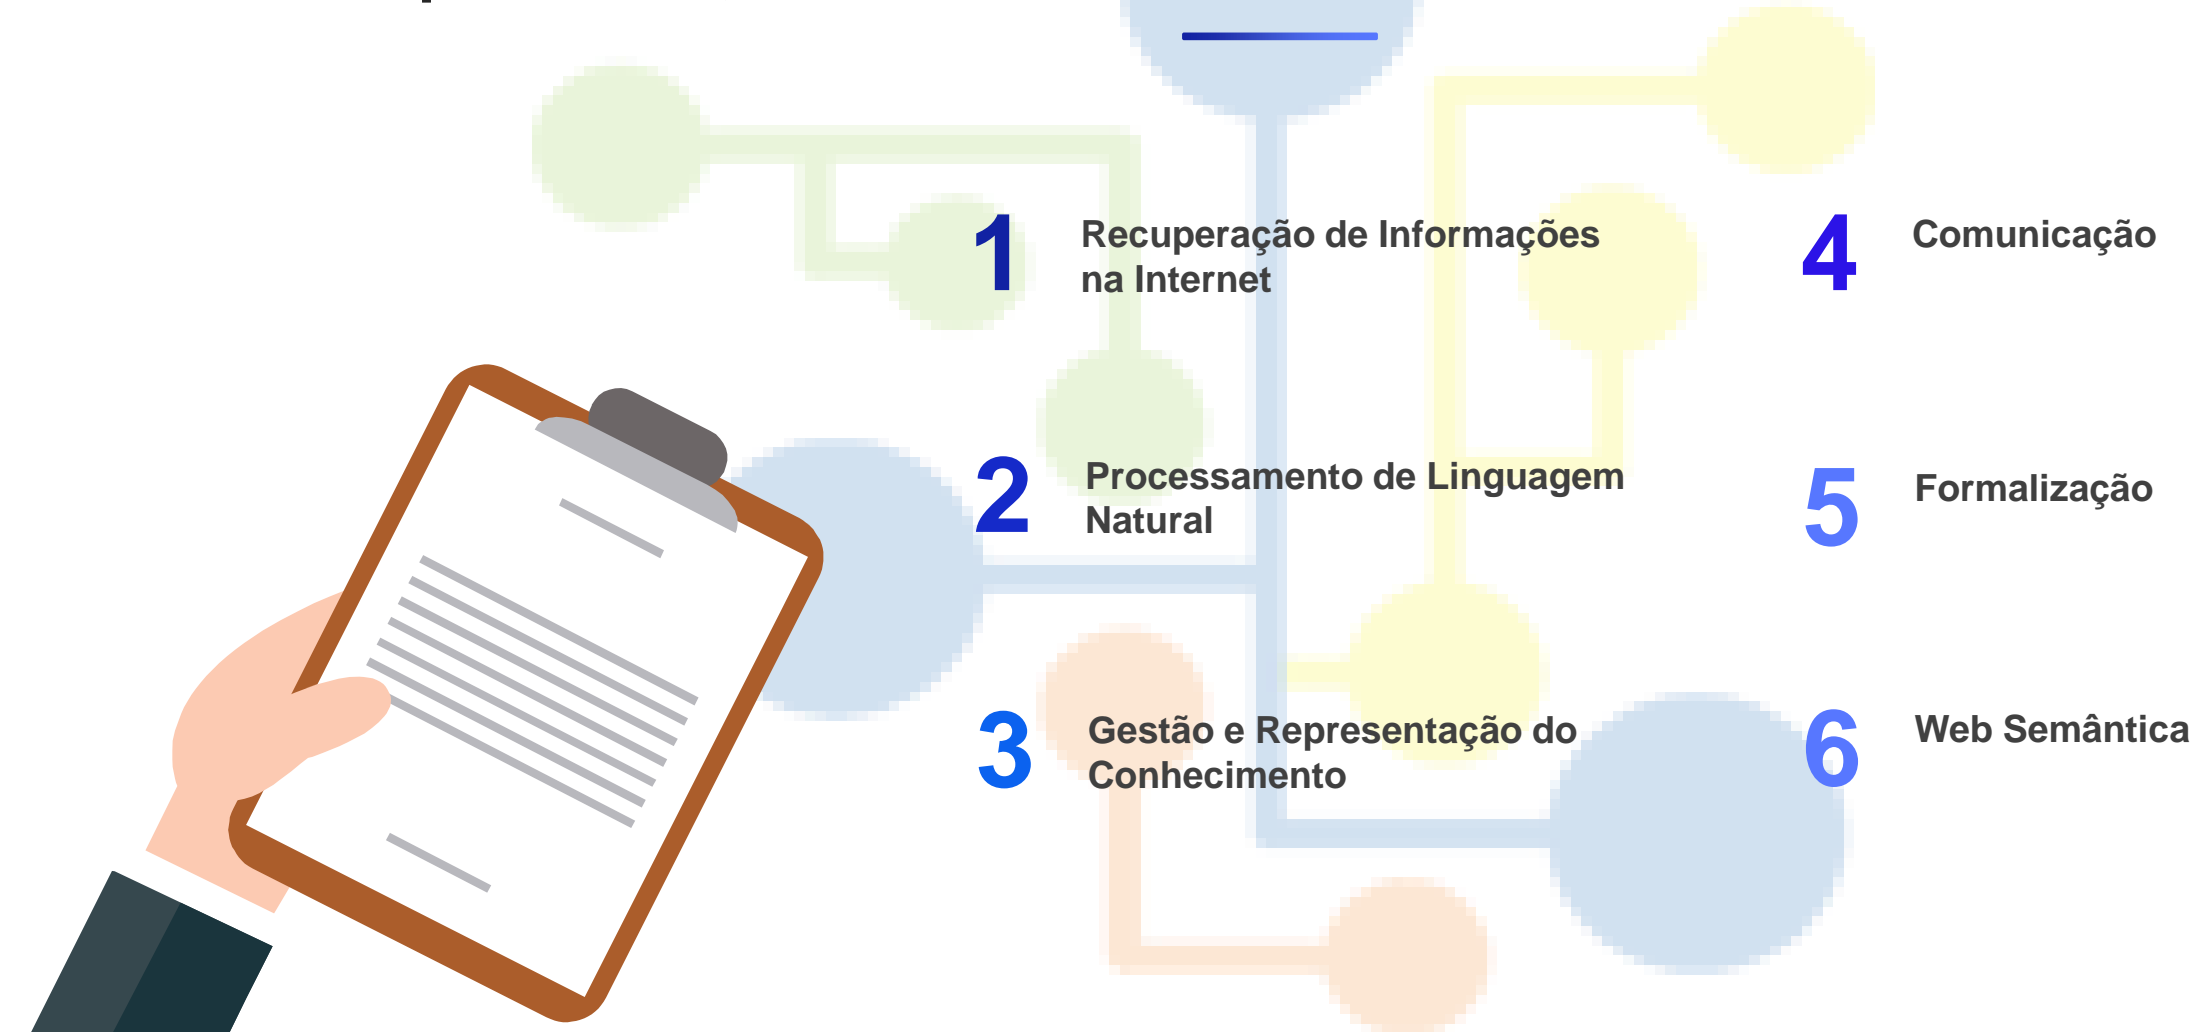
# Ontologia e Ciência da Computação

Apesar de apresentarem diferentes definições, o principal propósito da construção de ontologias é permitir compartilhamento e reutilização de conhecimento.





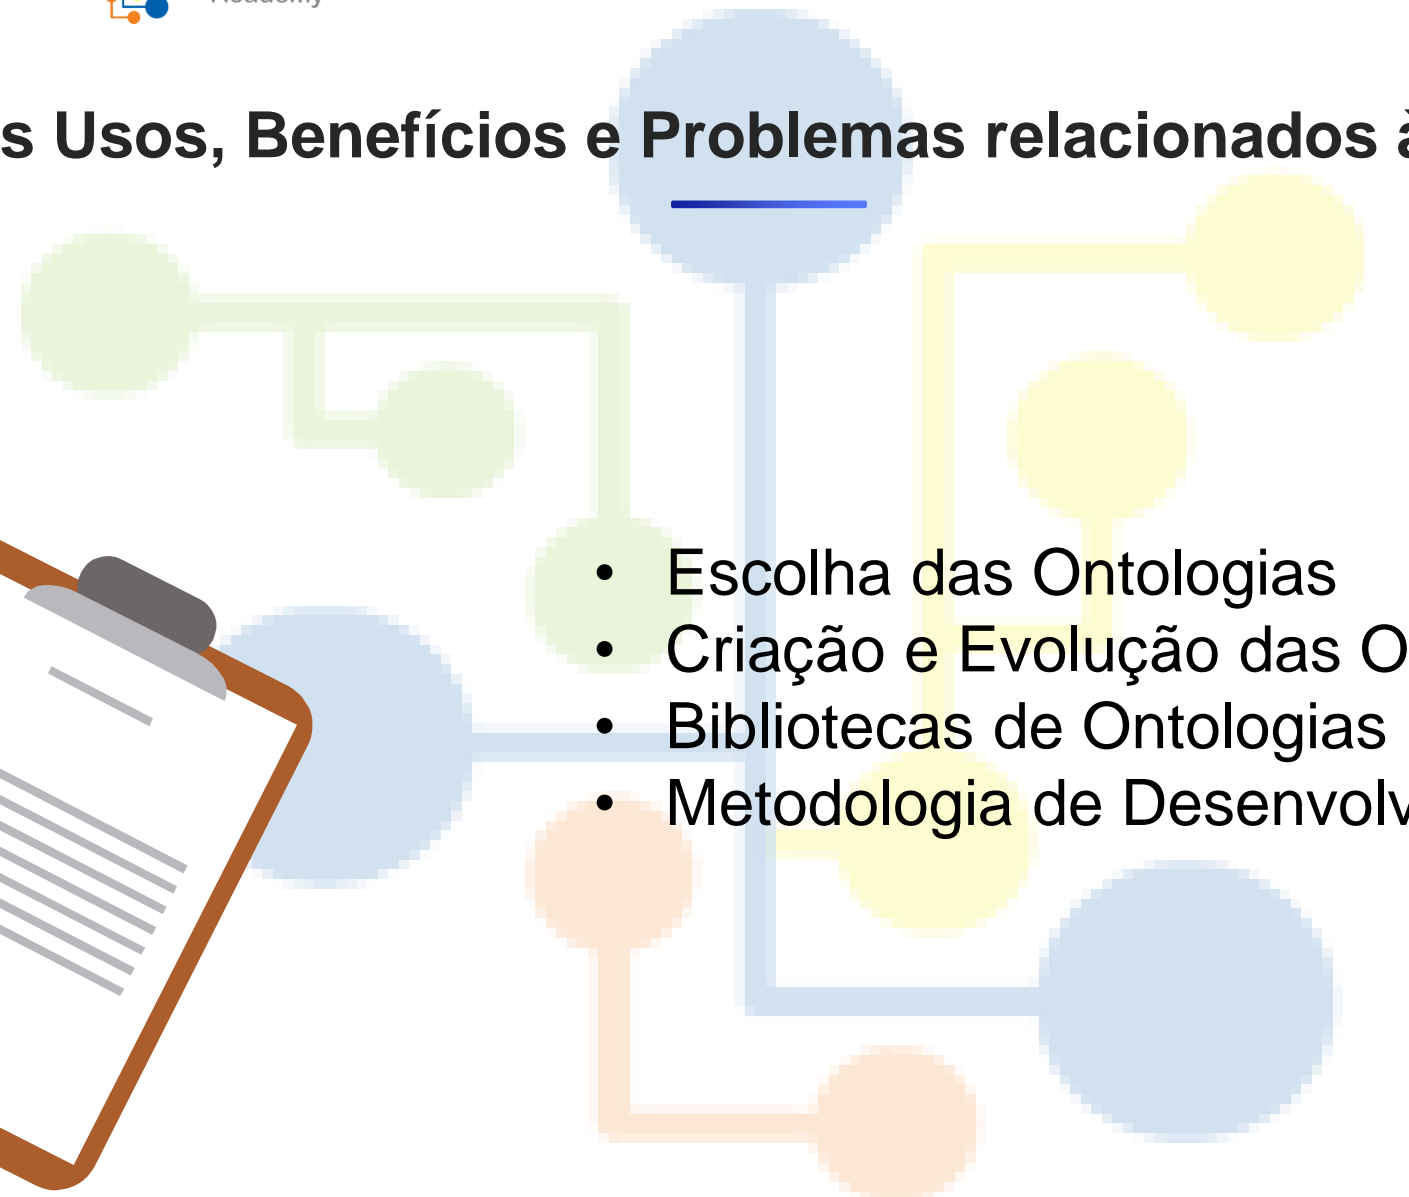
# Principais Usos, Benefícios e Problemas relacionados às Ontologias







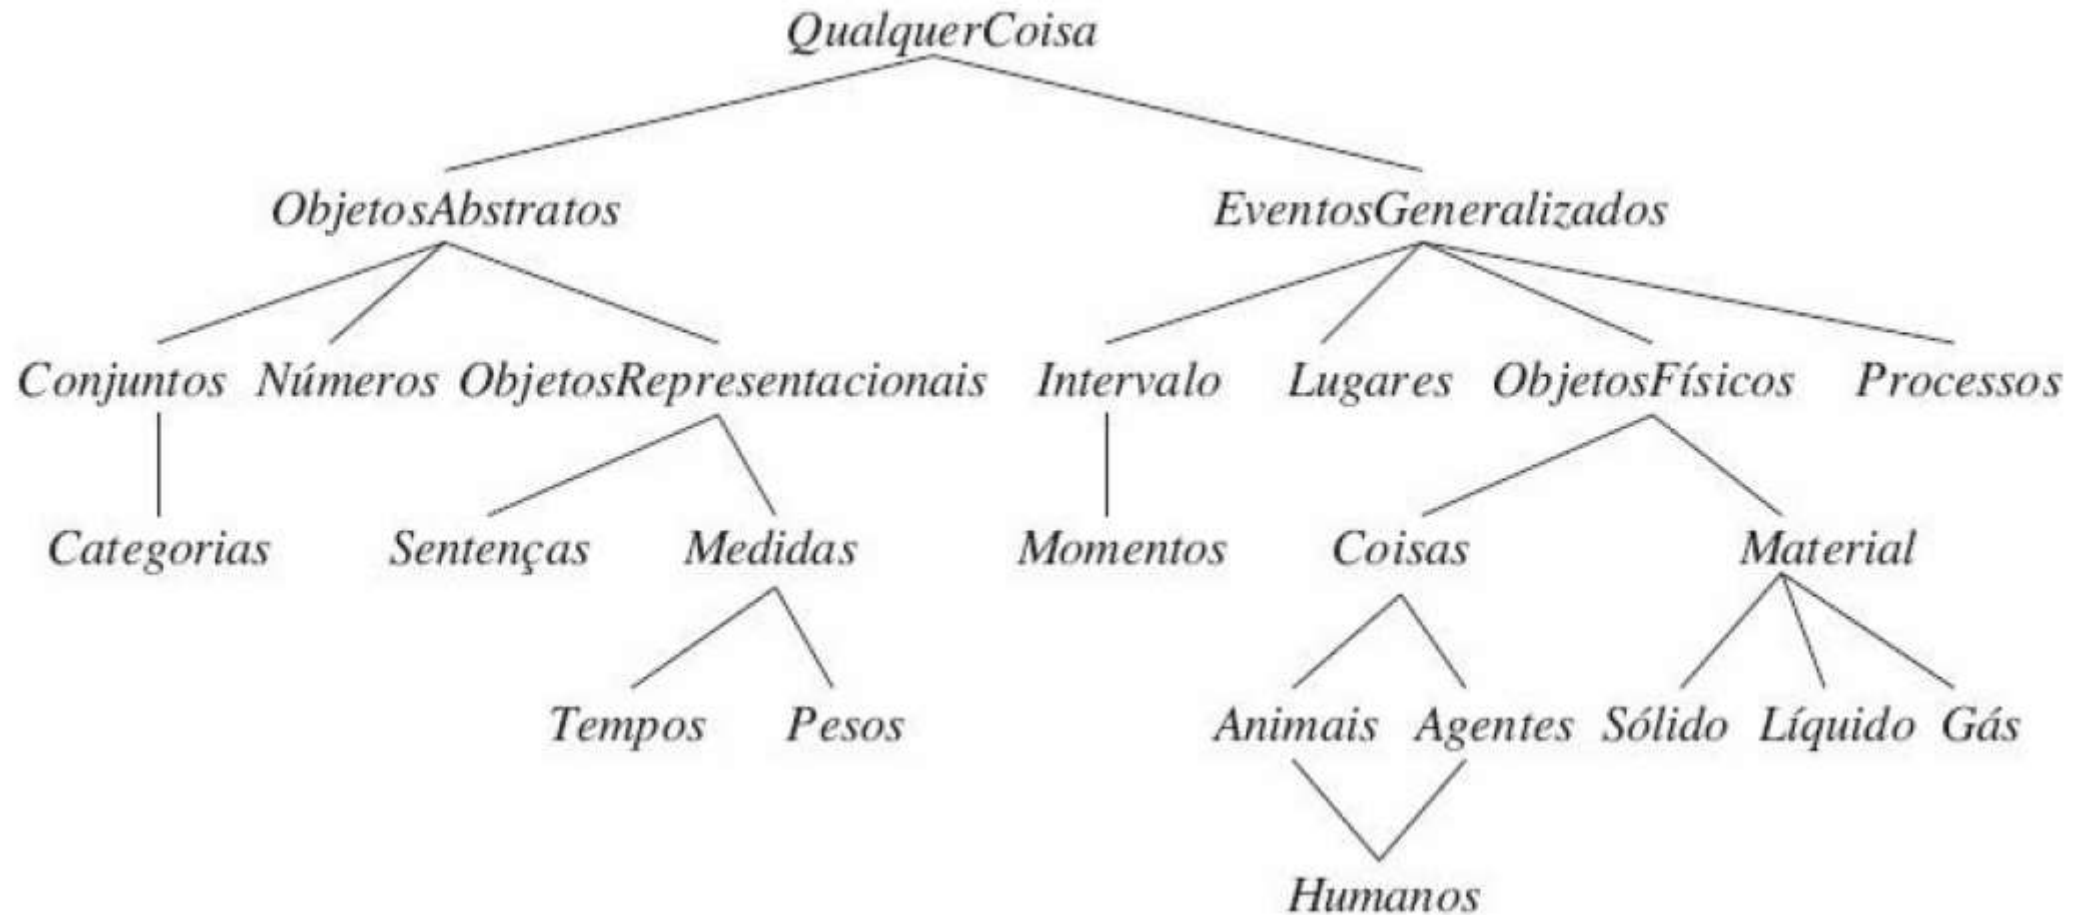
# Principais Usos, Benefícios e Problemas relacionados às Ontologias

- 
- A background diagram illustrating an ontology. It consists of several circular nodes of different colors (blue, green, yellow, orange) connected by lines. A hand holding a clipboard is positioned on the left side of the diagram.
- Escolha das Ontologias
  - Criação e Evolução das Ontologias
  - Bibliotecas de Ontologias
  - Metodologia de Desenvolvimento






# Engenharia Ontológica



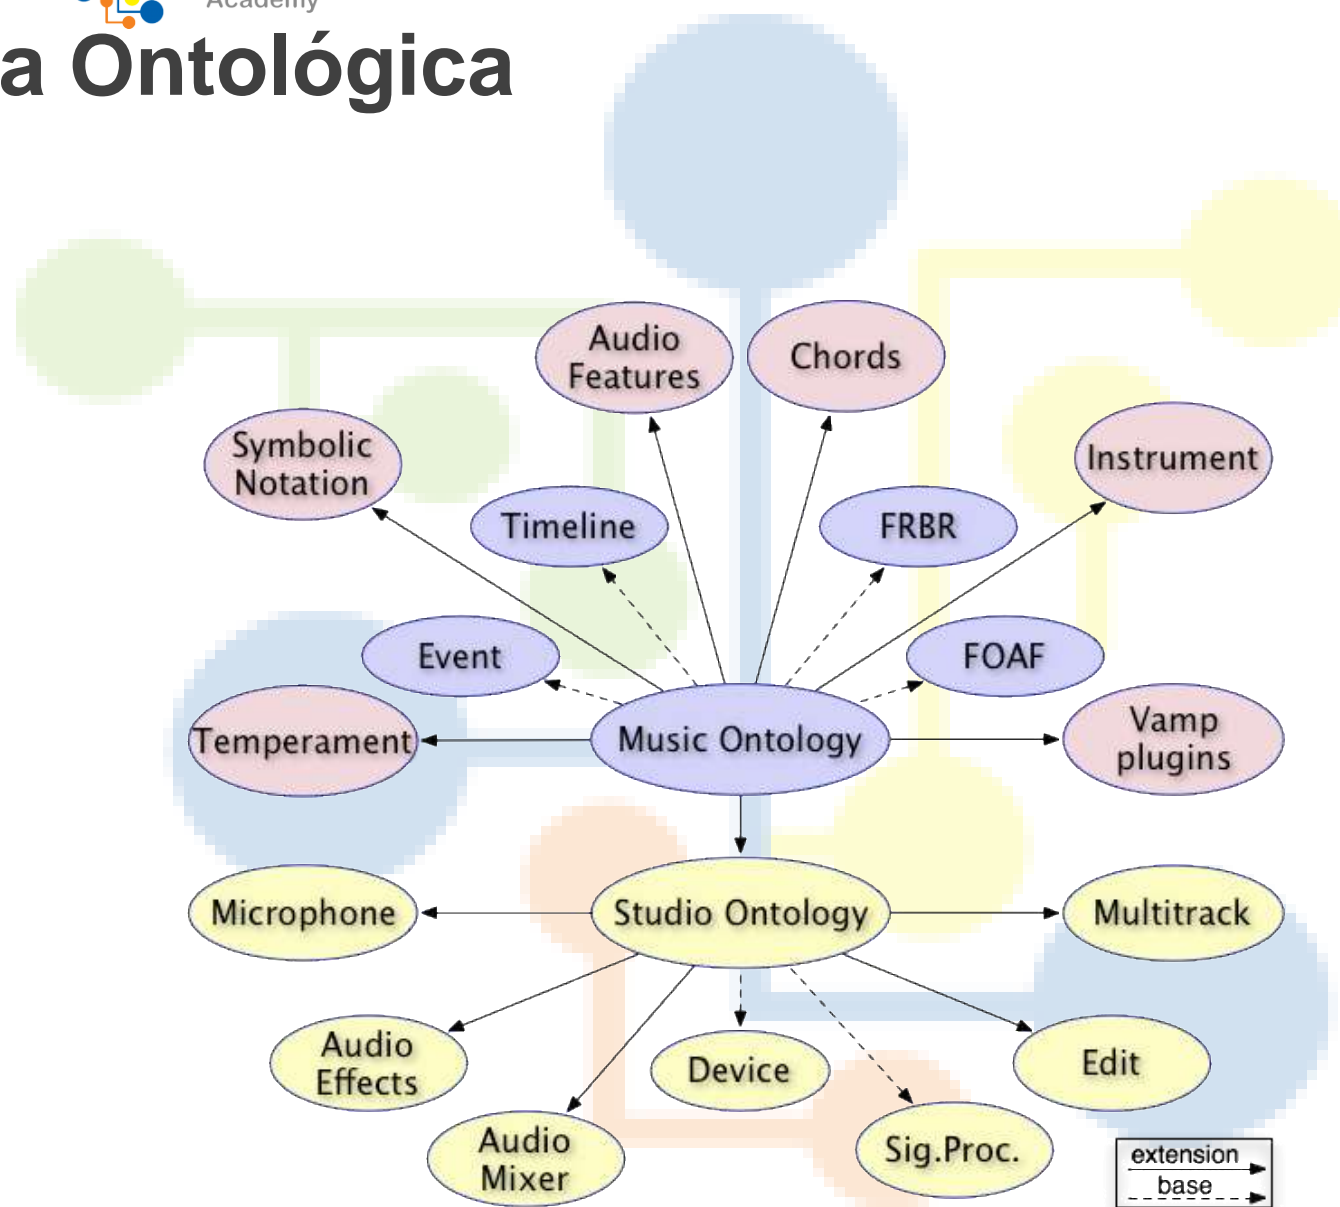


# Engenharia Ontológica





# Engenharia Ontológica





# Engenharia Ontológica

Uma ontologia de uso geral deve ser aplicável em quase todo domínio de uso específico (com a inclusão de axiomas específicos do domínio).





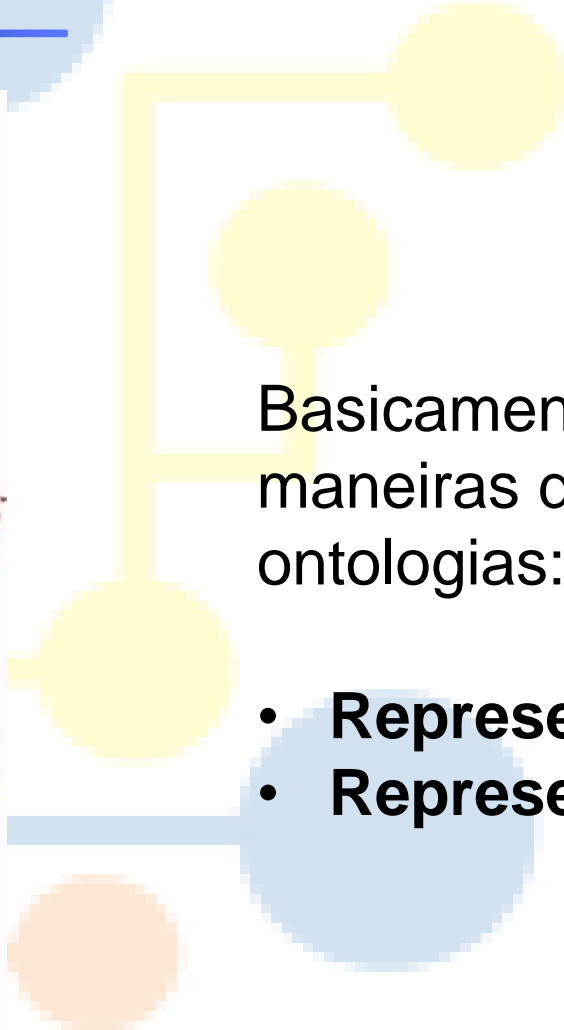


# Tipos de Ontologias

- 1 Ontologias Genéricas
- 2 Ontologias de Domínio
- 3 Ontologias de Tarefas
- 4 Ontologia de Aplicação



ção de




Basicamente existem duas maneiras de representar ontologias:

- **Representação formal**
- **Representação gráfica**



# Representação de Ontologias



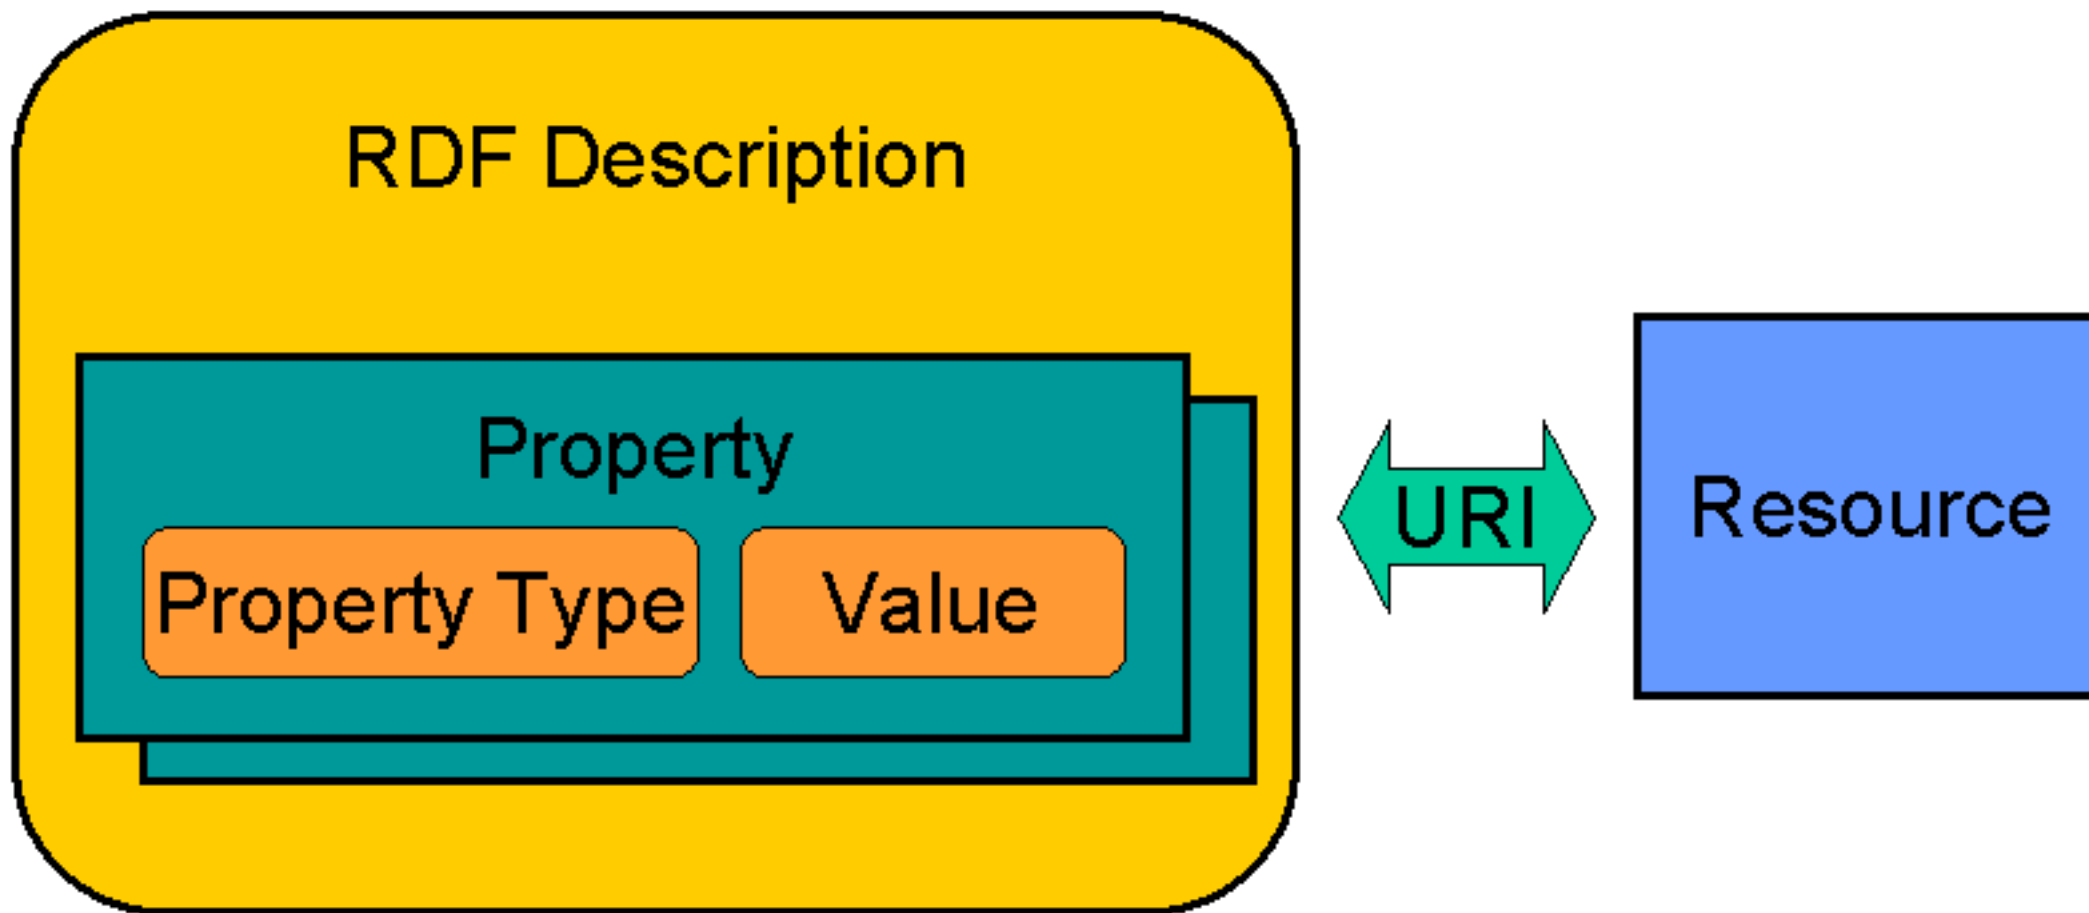
Basicamente existem duas maneiras de representar ontologias:

- Representação formal
  - **RDF**
  - **OWL**





# Representação de Ontologias







# Representação de Ontologias

```
<owl:Class rdf:ID="Vehicle">
  <rdfs:label>Vehicle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#Any" />
</owl:Class>
<owl:Class rdf:ID="sport_cycle">
  <rdfs:label>sport_cycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#bicycle" />
</owl:Class>
<owl:Class rdf:ID="city_cycle">
  <rdfs:label>city_cycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#bicycle" />
</owl:Class>
<owl:Class rdf:ID="bicycle">
  <rdfs:label>bicycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#Vehicle" />
  <rdfs:SubClassOf>
    <owl:Restriction>
      <owl:cardinality rdf:datatype="http://www.w3.org/"
      <owl:onProperty rdf:resource="#has_body_color" />
    </owl:Restriction>
  </rdfs:SubClassOf>
  <rdfs:SubClassOf>
    <owl:Restriction>
      <owl:onProperty rdf:resource="#has_body_color" />
      <owl:allValuesFrom rdf:resource="#Color" />
    </owl:Restriction>
  </rdfs:SubClassOf>
</owl:Class>
```

Web Ontology Language (OWL)

Figura 3.2 Representação da ontologia de bicicleta em OWL.  
Fonte: <http://www.hozo.jp/>



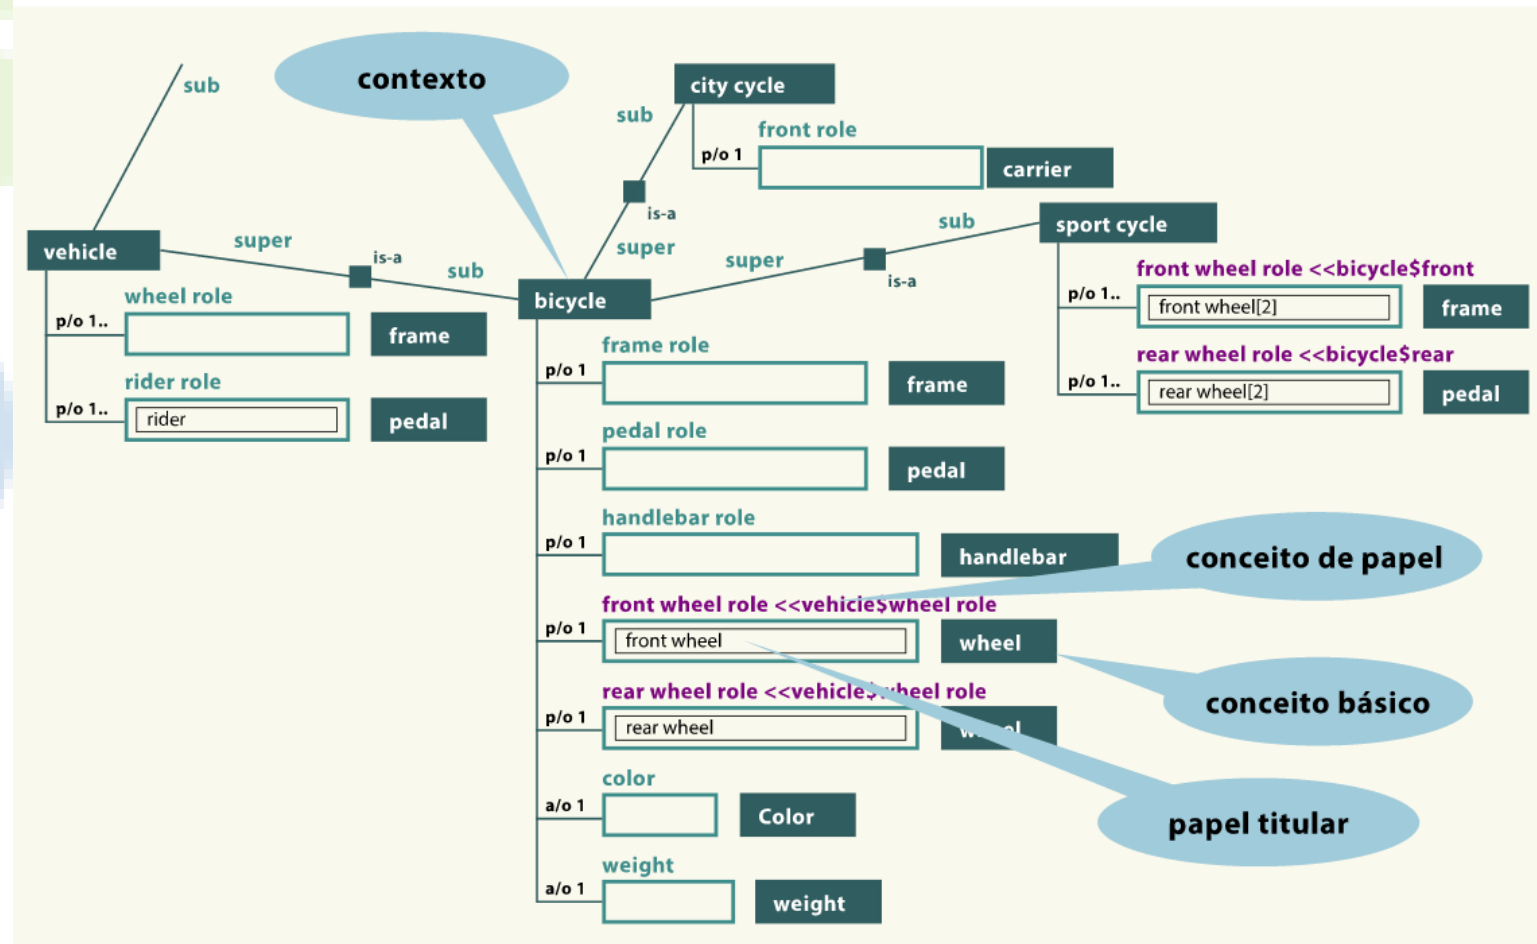




# Representação de Ontologias

Existem muitas maneiras de representar graficamente uma ontologia, uma vez que esta é composta principalmente por conceitos e suas relações.

Algumas formas comuns para representar graficamente ontologias são grafos, UML e estrutura de árvore.






# Construção de Ontologias

A construção de ontologias de domínio envolve, primeiramente, a definição de seu domínio e escopo.


- Relações
- Axiomas
- Instâncias
- Funções





# Construção de Ontologias


Percebeu a semelhança com linguagem de programação orientada a objetos?





# Construção de Ontologias

Lembra como construímos os agentes em Python ao fim do capítulo anterior usando orientação a objetos?







# Categorias e Objetos





# Categorias e Objetos



Representação de  
Conhecimento



# Categorias e Objetos

Predicados

Objetos

$\text{Elemento}(b, \text{BolasDeBasquete})$  para dizer que  $b$  é um elemento da **categoria** de bolas de basquete

$\text{Subconjunto}(\text{BolasDeBasquete}, \text{Bolas})$ , para dizer que  $\text{BolasDeBasquete}$  é uma **subcategoria** de  $\text{Bolas}$

\* Transformar uma proposição em um objeto é chamado de **reificação**, da palavra latina *res*, ou “coisa”.  
John McCarthy propôs o termo “coisificação”, mas o termo nunca vingou.





# Categorias e Objetos



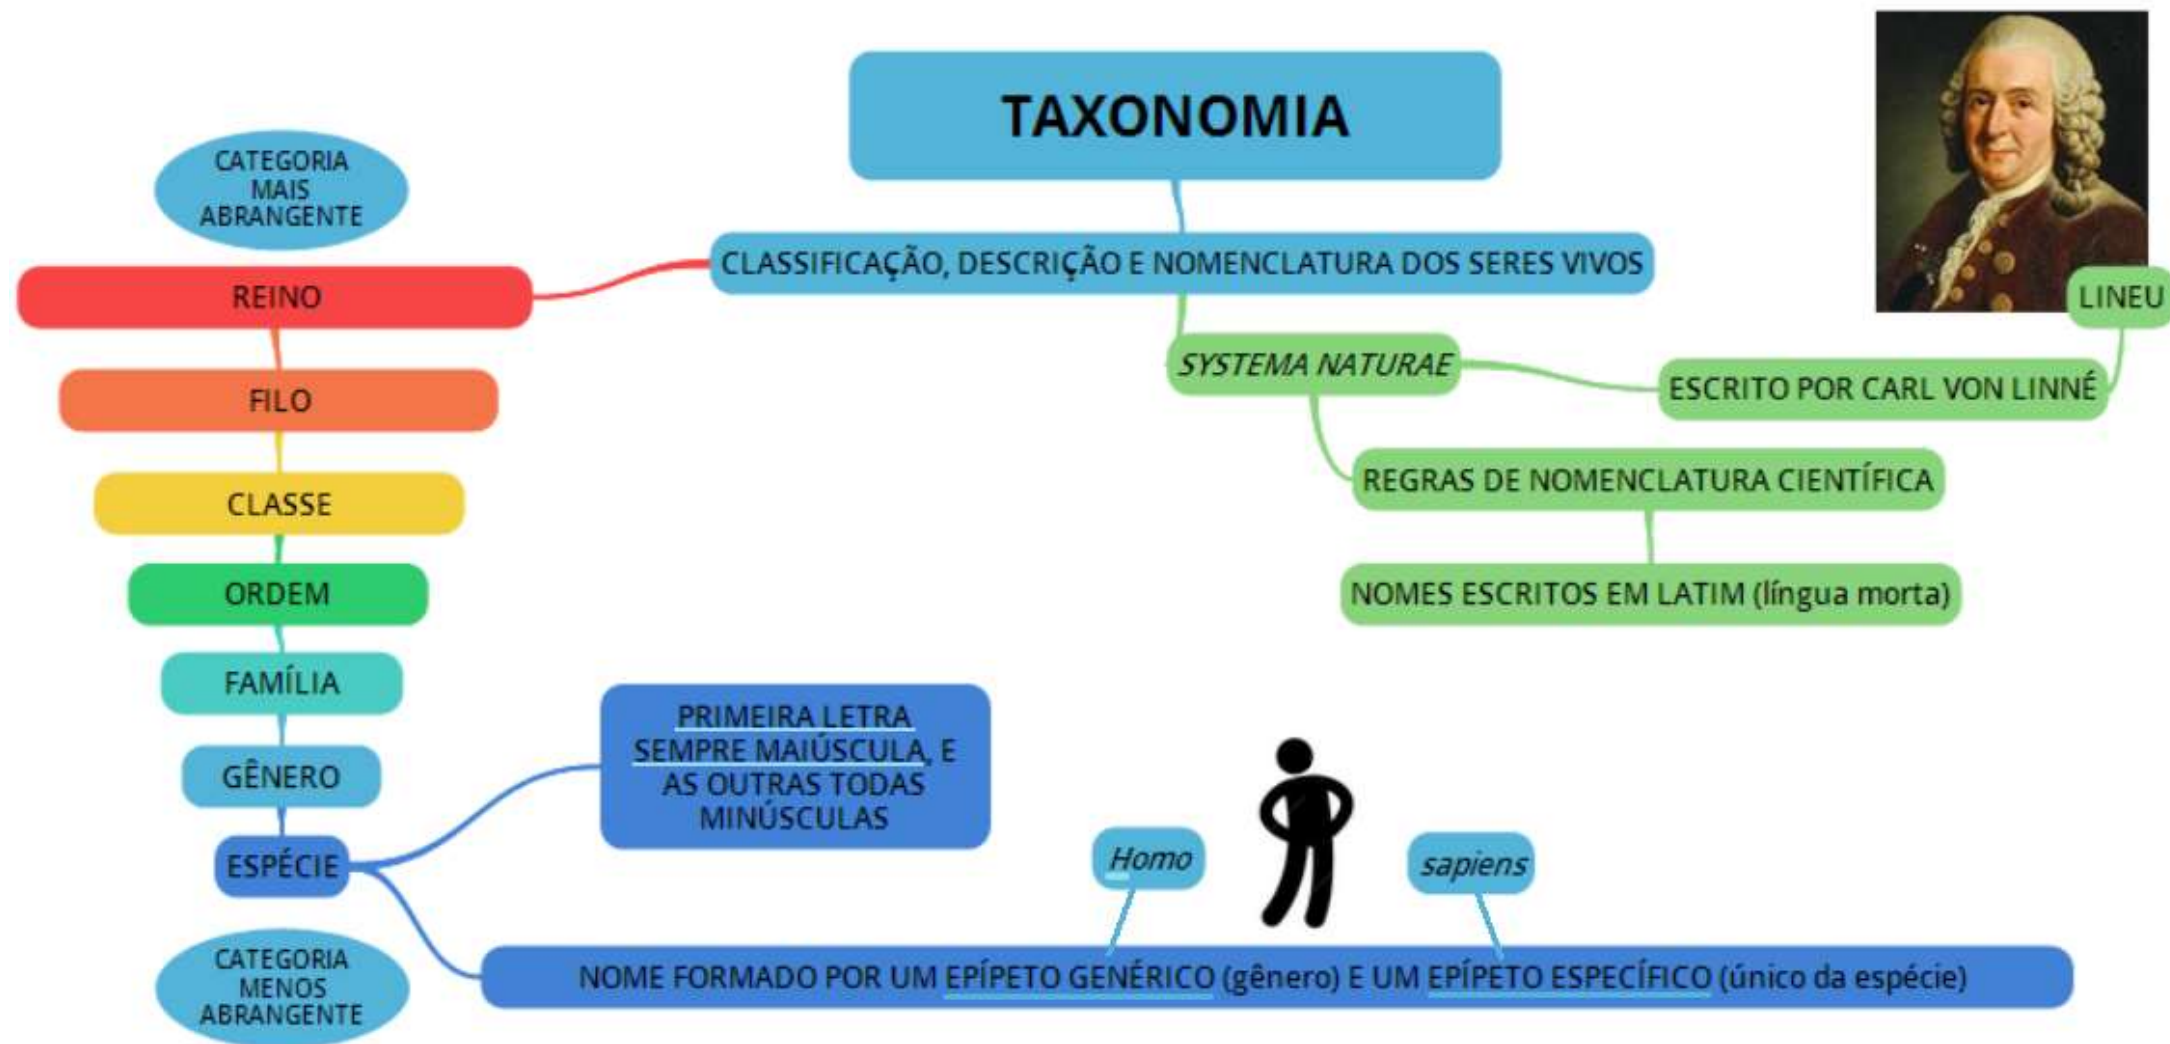
## Herança

Se dissermos que todas as instâncias da categoria *Alimento* são comestíveis e se afirmarmos que *Fruta* é uma subclasse de *Alimento* e que *Maçãs* é uma subclasse de *Fruta*, então saberemos que toda maçã é comestível.





# Categorias e Objetos





# Categorias e Objetos

- Um objeto é um elemento de uma categoria.
- Uma categoria é uma subclasse de outra categoria.
- Todos os elementos de uma categoria têm algumas propriedades.
- Os elementos de uma categoria podem ser reconhecidos por algumas propriedades.
- Uma categoria é um conjunto que tem algumas propriedades.





# Categorias e Objetos



***Disjuntos***(*{Animais, Vegetais}*)

***DecomposiçãoExaustiva***(*{Americanos, Canadenses, Mexicanos}, NorteAmericanos*)


***Partição***(*{Machos, Fêmeas}, Animais*)





# Categorias e Objetos

*GrupoDe({Maçã1, Maçã2, Maçã3})*







# Categorias e Objetos

Algumas categorias têm definições estritas: um objeto é um triângulo se e somente se é um polígono com três lados.

Por outro lado, a maioria das categorias no mundo real não tem nenhuma definição clara; essas são as chamadas categorias de **espécies naturais**.





# Sistemas de Raciocínio





# Sistemas de Raciocínio

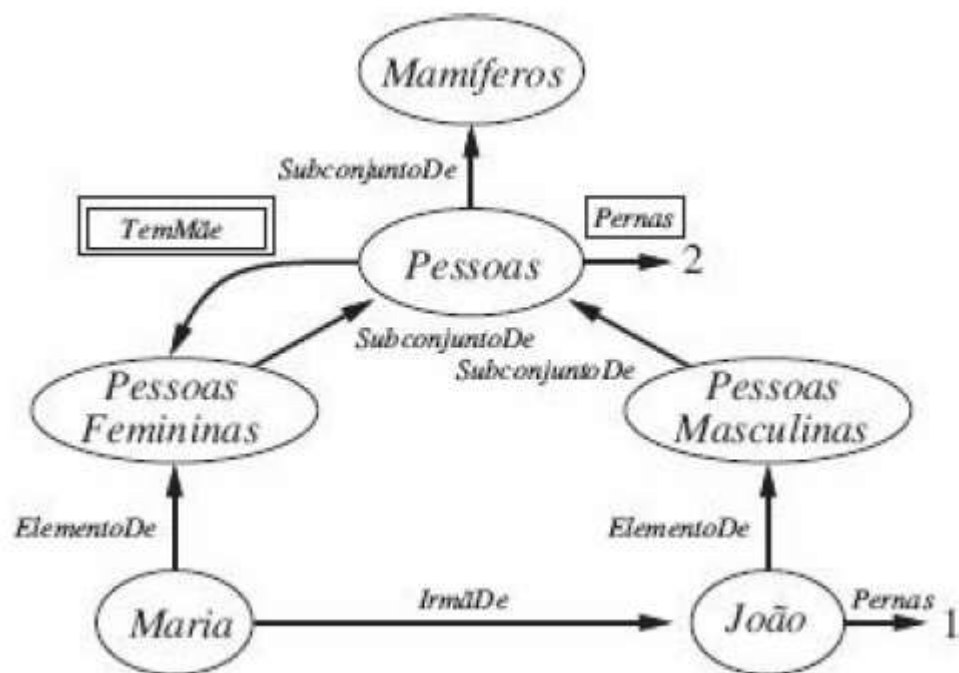
## Redes Semânticas

Oferecem auxílios gráficos para visualização de uma base de conhecimento e algoritmos eficientes para dedução de propriedades de um objeto, de acordo com sua pertinência a uma categoria.

## Lógicas de Descrição

Fornecem uma linguagem formal para construção e combinação de definições de categorias e algoritmos eficientes para definir relacionamentos de subconjuntos e superconjuntos entre categorias.






As redes semânticas — *pelo menos aquelas que têm semânticas bem definidas* — são uma forma de lógica.

# Redes Semânticas








Existem muitas variantes de redes semânticas, mas todas são capazes de representar objetos individuais, categorias de objetos e relações entre objetos.

# Redes Semânticas





O conceito foi criado para uso em computadores por Richard H. Richens em 1956 como uma língua internacional auxiliar para a tradução por máquina de linguagens naturais. Foram então desenvolvidas por Robert F. Simmons no início da década de 1960 e posteriormente amplidas através do trabalho de M. Ross Quillian em 1966.

# Redes Semânticas





Mecanismo de raciocínio de  
redes semânticas

# Redes Semânticas





## Algoritmo: Herança de Atributos



- Para recuperar um valor  $V$  de um atributo  $A$  de uma instância  $O$  de um objeto:
  1. Encontre  $O$  na base de conhecimento.
  2. Se houver aí um valor para o atributo  $A$ , retorne esse valor.
  3. Senão, verificar **se há um valor** para a relação *instância*.  
*Em caso negativo*, retorne *insucesso*.
  4. **Caso contrário**, ir para o nó que corresponde àquele valor e **procurar um valor** para o atributo  $A$ .  
*Se encontrar*, retorne o valor.
  5. **Caso contrário**, execute os passos a seguir até não haver mais valor para a relação *é-um* ou até encontrar uma resposta:
    - (a) Encontrar o valor da relação *é-um* e ir para aquele nó.
    - (b) Verificar se há um valor para o atributo  $A$ . Se houver, retorne-o.

# Redes Semânticas








A herança fica complicada quando um objeto pode pertencer a mais de uma categoria ou quando uma categoria pode ser um subconjunto de mais de uma outra categoria - isso se chama **herança múltipla**.

# Redes Semânticas





A semântica default é naturalmente imposta pelo algoritmo de herança porque segue arcos ascendentes desde o próprio objeto (João, nesse caso) e para tão logo encontra um valor.

# Redes Semânticas





As **lógicas de descrição** são notações projetadas para tornar mais fácil descrever definições e propriedades de categorias.

*Conceito* → **Thing** | *NomeConceito*  
| **And**(*Conceito*,...)  
| **All**(*NomePapel*, *Conceito*)  
| **AtLeast**(*Inteiro*, *NomePapel*)  
| **AtMost**(*Inteiro*, *NomePapel*)  
| **Fills**(*NomePapel*, *NomeIndivíduo*,...)  
| **SameAs**(*Caminho*, *Caminho*)  
| **OneOf**(*NomeIndivíduo*,...)  
  
*Caminho* → [*NomePapel*,...]

# Lógicas de Descrição





As principais tarefas de inferência para lógicas de descrição são a **subordinação** (verificar se uma categoria é um subconjunto de outra pela comparação de suas definições) e a **classificação** (verificar se um objeto pertence a uma categoria).

*Conceito* → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)

| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

*Caminho* → [*NomePapel*,...]

# Lógicas de Descrição







Linguagem Classic

Solteiro = And(NãoCasado, Adulto, Homem)

*Conceito* → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)

| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

*Caminho* → [*NomePapel*,...]

# Lógicas de Descrição





And(Homem, AtLeast(3, Filho), AtMost(2, Filha),  
All(Filho, And(Desempregado, Casado, All(Esposa, Médica))),  
All(Filha, And(Professora, Fills(Departamento, Física, Matemática))))

*Conceito* → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)

| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

*Caminho* → [*NomePapel*,...]

# Lógicas de Descrição





O aspecto mais importante das lógicas de descrição seja sua ênfase na tratabilidade da inferência.

*Conceito* → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)

| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

*Caminho* → [*NomePapel*,...]

# Lógicas de Descrição





# Quantificando a Incerteza







# Quantificando a Incerteza

Os agentes podem precisar lidar com a incerteza, seja devido a um ambiente parcialmente observável, ao não determinismo ou a uma combinação dos dois.





# Quantificando a Incerteza

Um plano de contingência correto que lida com toda eventualidade pode crescer arbitrariamente e deve considerar as contingências arbitrariamente improváveis.

Às vezes, não há um plano garantido de alcançar o objetivo — mesmo assim o agente deve agir. Deve ter alguma maneira de comparar os méritos dos planos que não são garantidos.





# Quantificando a Incerteza



Plano: A90







# Quantificando a Incerteza



Plano: A90



Plano: A180





# Quantificando a Incerteza



Portanto, a alternativa correta — *a decisão racional* — depende tanto da importância relativa de várias metas quanto da probabilidade de que elas serão alcançadas e em que grau.





# Quantificando a Incerteza

*DorDeDente → Cárie.*

*DorDeDente → Cárie ∨ Gengivite ∨ Abscessos...*

*Cárie → DorDeDente.*

Tentar usar a lógica de primeira ordem para lidar com um domínio como diagnóstico médico é uma abordagem falha, por três razões principais:

- **Preguiça**
- **Ignorância teórica**
- **Ignorância prática**





# Quantificando a Incerteza

*DorDeDente*  $\rightarrow$  *Cárie*.

*DorDeDente*  $\rightarrow$  *Cárie*  $\vee$  *Gengivite*  $\vee$  *Abscessos*...

*Cárie*  $\rightarrow$  *DorDeDente*.

Nossa principal ferramenta para lidar com graus de crença será a **teoria da probabilidade**.

Um agente lógico acredita que cada sentença seja verdadeira ou falsa ou não tem opinião, enquanto um agente probabilístico pode ter um grau de crença numérico entre 0 (para sentenças que são certamente falsas) e 1 (certamente verdadeiras).








Hummm... Está começando a fazer sentido!!!!



# Quantificando a Incerteza

*A probabilidade proporciona um meio para **resumir** a incerteza que vem de nossa preguiça e ignorância, resolvendo assim o problema de qualificação.*








# Quantificando a Incerteza

Um ponto confuso é que, no momento do nosso diagnóstico, não há incerteza no mundo real: o paciente tem uma cárie ou não. Então, o que significa dizer que a probabilidade de uma cárie é de 0,8? Não deveria ser 0 ou 1?





# Quantificando a Incerteza

## Incerteza e decisões racionais



Plano: A90  
Plano: A180  
Plano: A1440





# Quantificando a Incerteza



A teoria da utilidade diz que todo estado tem determinado grau de utilidade (ou seja, ele tem certa utilidade) para um agente e que o agente preferirá estados com utilidade mais alta.





# Quantificando a Incerteza

Por exemplo, a utilidade de um estado em uma partida de xadrez em que a peça branca colocou a preta em xeque é obviamente alta para o agente que joga com a branca, mas baixa para o agente que joga com a preta.





# Quantificando a Incerteza

*Teoria da decisão = teoria da probabilidade + teoria da utilidade*







# Quantificando a Incerteza

**função** AGENTE-TD(*percepção*) **retorna** uma *ação*

**variáveis estáticas:** *estado\_de\_crença*, crenças probabilísticas sobre o estado atual do mundo  
*ação*, a ação do agente

atualizar *estado\_de\_crença* com base em *ação* e *percepção*

calcular probabilidades de resultados de ações,

dadas descrições de ações e o *estado\_de\_crença* atual

selecionar *ação* com utilidade esperada mais alta

dadas as probabilidades de resultados e informações de utilidade

**retornar** *ação*





# Quantificando a Incerteza





# Quantificando a Incerteza


Na teoria da probabilidade, o conjunto de todos os mundos possíveis é chamado de **espaço amostral**





# Quantificando a Incerteza

Por exemplo, se jogamos dois dados (distintos), existem 36 mundos possíveis a considerar:  $(1,1), (1,2), \dots, (6,6)$ . A letra grega  $\Omega$  (ômega maiúsculo) é usada para se referir ao espaço amostral, e  $\omega$  (ômega minúsculo) refere-se aos elementos do espaço, isto é, aos mundos possíveis particulares.






# Quantificando a Incerteza

$$0 \leq P(\omega) \leq 1 \text{ para cada } \omega \text{ e } \sum_{\omega \in \Omega} P(\omega) = 1$$

Se assumirmos que os dois dados não são “viciados” e um lançamento não interfere no outro, cada um dos mundos possíveis (1,1), (1,2),..., (6,6) tem probabilidade 1/36.







# Quantificando a Incerteza

Em IA, os conjuntos são sempre descritos por **proposições** em uma linguagem formal. Para cada proposição, o conjunto correspondente contém apenas aqueles mundos possíveis onde a proposição é válida. A probabilidade associada a uma proposição é definida como sendo a soma das probabilidades dos mundos nos quais é válida:

$$\text{Para qualquer proposição } \phi, P(\phi) = \sum_{\omega \in \phi} P(\omega)$$






# Quantificando a Incerteza

Por exemplo, ao jogar dados que não são viciados, temos:

$$P(\text{Total} = 11) = P((5, 6)) + P((6, 5)) = 1/36 + 1/36 = 1/18$$






# Quantificando a Incerteza

Probabilidades, tais como  $P(\text{Total} = 11)$  e  $P(\text{duplas})$  são chamadas **probabilidades incondicionais** ou **anteriores**.

Da mesma forma, se eu estou indo ao dentista para um *check-up* regular, a probabilidade  $P(\text{cárie}) = 0,2$  pode ser interessante, mas se estou indo ao dentista porque tenho uma dor de dente, é  $P(\text{cárie} \mid \text{dor de dente}) = 0,6$  que importa.





# Quantificando a Incerteza

É importante compreender que  $P(\text{cárie}) = 0,2$  ainda é válido após a dor de dente ter sido observada;

Ela simplesmente não é especialmente útil.





# Quantificando a Incerteza

Matematicamente falando, as probabilidades condicionais são definidas em termos de probabilidades incondicionais como segue:

para quaisquer proposições  $a$  e  $b$ , temos:

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)},$$

que é válido sempre que  $P(b) > 0$ . Por exemplo,

$$P(\text{dupla} \mid \text{Dado}_1 = 5) = \frac{P(\text{dupla} \wedge \text{Dado}_1 = 5)}{P(\text{Dado}_1 = 5)},$$








# Quantificando a Incerteza

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)}$$



$$P(a \wedge b) = P(a \mid b) P(b)$$






# A Regra de Bayes






# A Regra de Bayes





# A Regra de Bayes

Em teoria da probabilidade o Teorema de Bayes mostra a relação entre uma probabilidade condicional e a sua inversa.





# A Regra de Bayes

O primeiro a empregar o método bayesiano em problemas de física foi o matemático francês Pierre de Simon Laplace.







# A Regra de Bayes

Graças ao grande aumento na capacidade de processamento dos computadores, a abordagem bayesiana tem renascido com grande força.





# A Regra de Bayes

$$\Pr(A|B) = \frac{\Pr(B|A) \Pr(A)}{\Pr(B)}$$


- $\Pr(A)$  e  $\Pr(B)$  são as probabilidades a priori de A e B.
- $\Pr(B|A)$  e  $\Pr(A|B)$  são as probabilidades a posteriori de B condicional a A e de A condicional a B respectivamente.





# A Regra de Bayes

A principal crítica à teoria bayesiana é que ela tem um fator que é *subjetivo*, a escolha do prior (prévio).








# A Regra de Bayes

A principal crítica à teoria bayesiana é que ela tem um fator que é *subjetivo*, a escolha do prior.

Dados são inúteis se eles não estiverem contextualizados.






# A Regra de Bayes

A regra de Bayes, muito além de um resultado matemático útil, dá origem a toda uma visão de mundo e quantifica o que é *ser racional*.

A expressão matemática do teorema de Bayes liga a inferência racional (probabilidade posterior) com a subjetividade das nossas visões prévias (prior) e as evidências empíricas.







# A Regra de Bayes

O teorema de Bayes liga a razão humana ao universo físico.





# Raciocínio Probabilístico





# Raciocínio Probabilístico





# Raciocínio Probabilístico

Representação do Conhecimento em um Domínio Incerto

As redes bayesianas podem representar essencialmente qualquer distribuição de probabilidade conjunta completa.

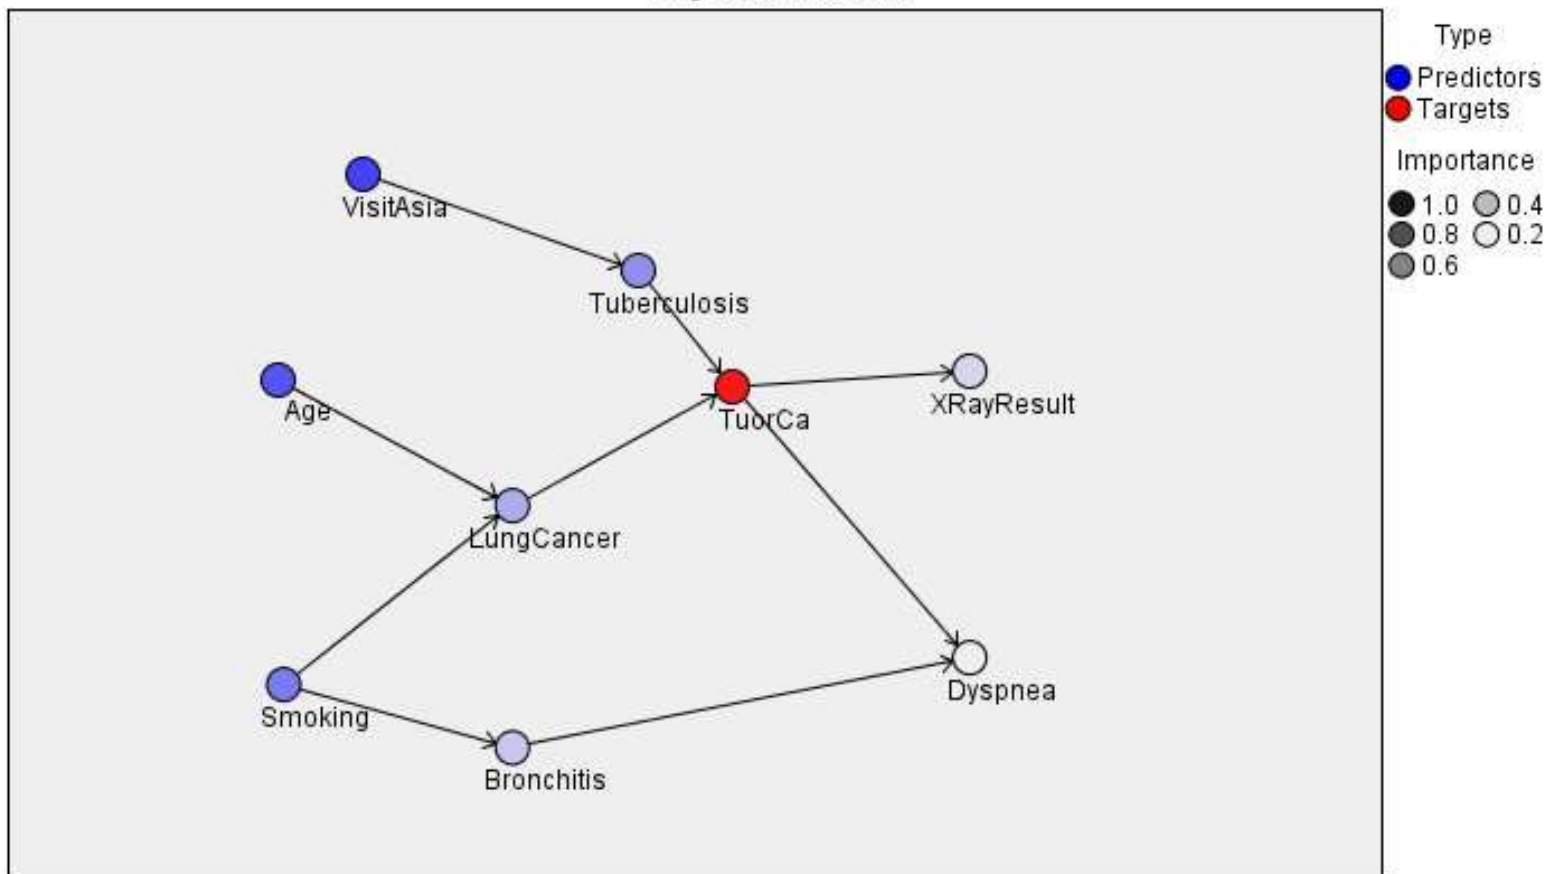




# Raciocínio Probabilístico

1. Cada nó corresponde a uma variável aleatória, que pode ser discreta ou contínua.
2. Um conjunto de vínculos orientados ou setas conecta pares de nós. Se houver uma seta do nó  $X$  até o nó  $Y$ ,  $X$  será denominado *pai* de  $Y$ . O grafo não tem ciclos orientados (e, portanto, é um grafo acíclico orientado, ou GAO).
3. Cada nó  $X_i$  tem uma distribuição de probabilidade condicional  $P(X_i | Pais(X_i))$  que quantifica o efeito dos pais sobre o nó.


Bayesian Network







# Raciocínio Probabilístico

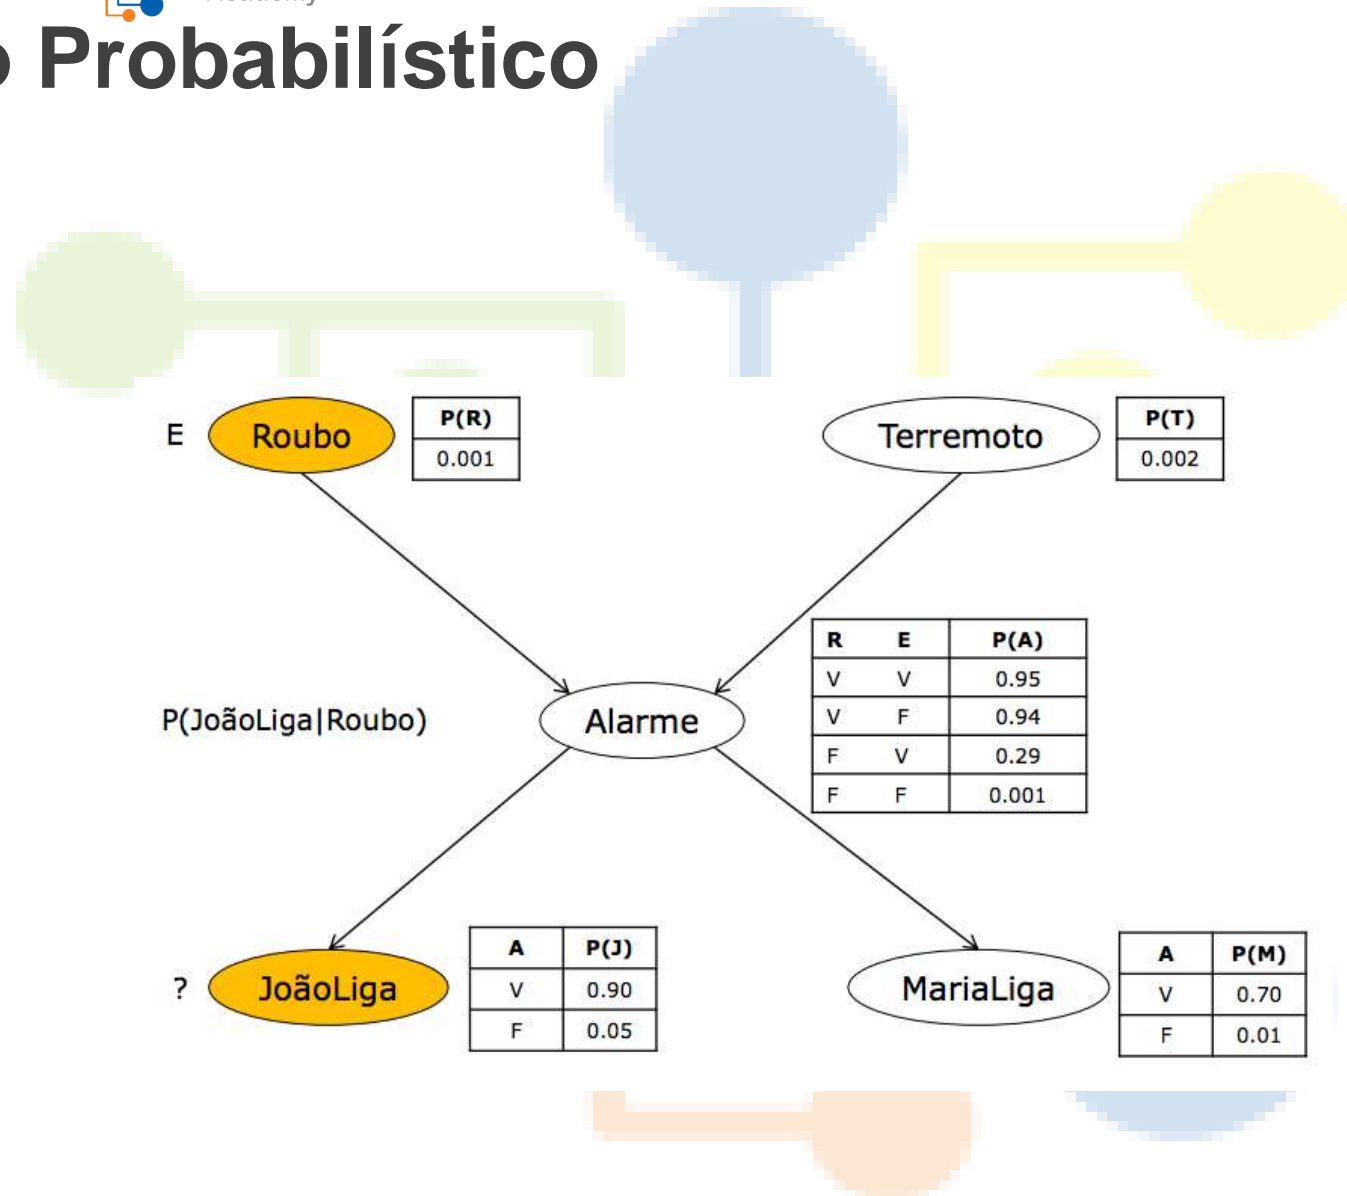


Formalmente, a independência condicional de *DorDeDente* e *Boticão* dada *Cárie* é a ausência de um vínculo entre *DorDeDente* e *Boticão*. Intuitivamente, a rede representa o fato de que *Cárie* é uma causa direta de *DorDeDente* e *Boticão*, enquanto não existe nenhum relacionamento causal direto entre *DorDeDente* e *Boticão*.



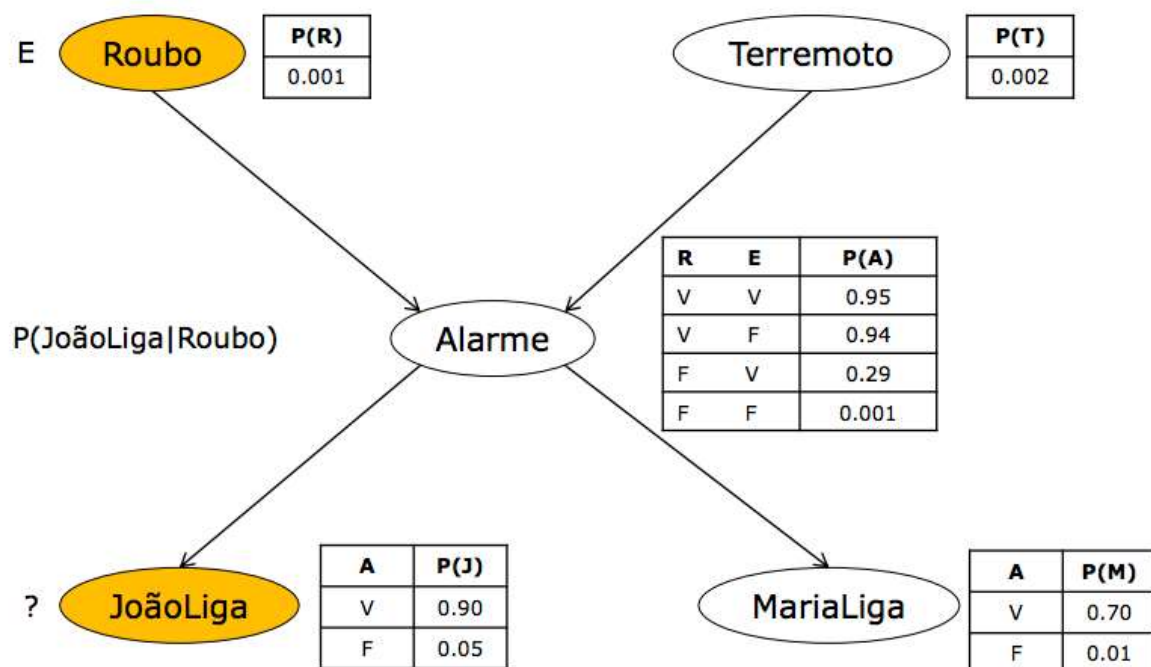


# Raciocínio Probabilístico





# Raciocínio Probabilístico




Uma rede bayesiana típica, mostrando a topologia e também as tabelas de probabilidade condicional (TPCs).

Nas TPCs, as letras *R*, *T*, *A*, *J* e *M* representam *Roubo*, *Terremoto*, *Alarme*, *JoãoLiga* e *MariaLiga*, respectivamente.





# Raciocínio Probabilístico



Note que a rede não tem nós correspondentes ao fato de Maria estar ouvindo música em alto volume no momento ou ao fato de o telefone tocar e confundir João. Esses fatores são resumidos na incerteza associada aos vínculos de *Alarme* para *JoãoLiga* e *MariaLiga*.





# Raciocínio Probabilístico Temporal









# Raciocínio Probabilístico Temporal

Tempo e Incerteza





# Raciocínio Probabilístico Temporal

## Tempo e Incerteza

As mesmas considerações surgem em muitos outros contextos, tal como acompanhar a localização do robô, o controle da atividade econômica de uma nação, até dar sentido a uma sequência de palavras faladas. Como é possível modelar situações dinâmicas como essas?







# Raciocínio Probabilístico Temporal

## Tempo e Incerteza

Vemos o mundo como uma série de instantâneos, ou fatias de tempo, cada uma das quais contém um conjunto de variáveis aleatórias, algumas observáveis, e outras, não!

**$X_t$**  para indicar o conjunto de variáveis de estados no tempo  $t$

**$E_t$**  para indicar o conjunto de variáveis de evidência observáveis





# Raciocínio Probabilístico Temporal

## Tempo e Incerteza

- **Variáveis de evidência:**
  - AçúcarNoSangueMedidot
  - Pulsaçãot
- **Variáveis de estado:**
  - AçúcarNoSanguet
  - ConteúdoDoEstômagot

$X_t$  para indicar o conjunto de variáveis de estados no tempo  $t$

$E_t$  para indicar o conjunto de variáveis de evidência observáveis







# Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(X_t | X_{0:t-1})$$

$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$$






# Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$$



Modelo de transição para um processo de Markov de segunda ordem.

$$P(X_t | X_{t-2}, X_{t-1})$$







# Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(E_t | X_{0:t}, E_{0:t-1}) = P(E_t | X_t)$$





# Raciocínio Probabilístico Temporal

## Inferência em Modelos Temporais

- **Filtragem**
- **Previsão**
- **Suavização**
- **Explicação Mais Provável**
- **Aprendizagem**





# Raciocínio Probabilístico Temporal

O aprendizado exige a inferência de suavização total, e não a filtragem, porque a suavização fornece melhores estimativas dos estados do processo.







Data Science  
Academy

Data Science Academy angelicogfa@gmail.com 5b81f7e45e4cdea2118b4569

# Obrigado



Data Science Academy



Data Science Academy